次元圧縮を適用した深層学習に基づくリアルタイム浸水域予測の高度化

中山　龍也[1]・山口　歓太[2]・一言　正之[3]・樫山　和男[4]

[1] 中央大学大学院　理工学研究科都市人間環境学専攻（〒112-8551 東京都文京区春日 1-13-27）
E-mail: a20.3emg@g.chuo-u.ac.jp (Corresponding Author)

[2] 中央大学大学院　理工学研究科都市人間環境学専攻（〒112-8551 東京都文京区春日 1-13-27）
E-mail: a21.6ff7@g.chuo-u.ac.jp

[3] 正会員　日本工営株式会社　河川水資源事業部　河川計画部（〒102-8539 東京都千代田区麹町 5-4）
E-mail: hitokoto-ms@n-koei.jp

[4] 正会員　中央大学教授（〒112-8551 東京都文京区春日 1-13-27）
E-mail: kaz@civil.chuo-u.ac.jp

本論文は，従来の数値解析による氾濫域予測の代替手法として，深層学習と次元圧縮技術を組み合わせた浸水域予測手法を提案し，その汎化性能および予測精度の向上について検討を行ったものである．次元圧縮手法として，特異値分解（SVD），非負値行列因子分解（NMF），およびオートエンコーダ（AE）を採用し，深層学習手法としては，DNN，RNN，LSTM，GRU を用いた．DNN を用いた浸水域予測手法は荒川の浸水シミュレーションに適用し，リアルタイム性と精度の両面から手法の妥当性を検証した．また，浸水域の時間的変化を考慮するために時系列処理に適した RNN，LSTM，GRU の適用も行った．その結果，約 22 万次元の浸水域データを 10 次元まで圧縮しても高精度かつ高速な予測が可能であり，特に NMF は精度と計算効率のバランスに優れることが確認された．また，LSTM は DNN と比較して予測精度の向上に寄与することが確認された．

Key Words: *Deep Learning, Inundation Simulation, Dimensionality Compression, Real-time Simulation*

1. はじめに

近年，線状降水帯やゲリラ豪雨などの異常気象が頻発しており，日本各地で甚大な水害が発生している．こうした極端な気象の背景には，気候変動や都市化の進行といった複合的な要因があり，今後も水害リスクの増大が懸念される．したがって，浸水被害を最小限に抑えるためには，降雨状況や河川水位の変化を迅速に把握し，事前に浸水域を予測することが重要である．特に，リアルタイム性と高解像度の両立を図る浸水域予測技術の構築は，防災対応や住民の避難判断において不可欠である．数値シミュレーションを用いた浸水域予測に関しては，Teng ら[1]が計算効率の高い TVD モデルを用いた簡易な氾濫予測を実施している．また，Hoch ら[2]は広域洪水シミュレーションにおいてフレキシブルメッシュを活用することで，計算効率と解像度の両立を図った．これらの物理ベースの手法は高い予測精度を有する一方で，計算資源の消費が大きく，リアルタイム性の確保には課題が残る．この課題に対して，近年では深層学習を用いた浸水域予測の研究が盛んに行われている．Chiu ら[3]は，主成分分析（PCA）と機械学習を組み合わせたアンサンブル学習によって浸水域の予測精度を向上させた．また，Zhou ら[4]は U-Net による空間次元の削減と 1D-CNN の組み合わせにより，リアルタイム予測を実現している．さらに，LSTM を用いて代表地点の水位を予測し，2 次元線形補間により浸水域を再構成する手法も提案[5]している．Kao ら[6]は，階層的な学習により高次元データの深いパターンを捉えることが可能な Stacked AutoEncoder（SAE）と RNN を統合し，高次元洪水データに対する効率的な予測モデルを構築している．これらの研究はいずれも，高い予測精度を保持しつつ，即時性を持つ．

同様に著者ら[7]も，物理シミュレーションにより得られた浸水域データに対して次元圧縮を適用し，その係数を DNN で予測することで，リアルタイム性と予測精度の両立を図る手法を提案した．次元圧縮手法としては，次元圧縮手法で一般的な特異値分解（SVD）[8]，非負値のデータに適している非負値行列因子展開（NMF）[9]，基礎的な次元削減手法で，単純な構造を持つオートエンコーダ（AE）[10]の 3 手法を用いて，いずれの手法でも高精度かつ高速な浸水域予測が可能であることを確認した．しかしながら，既往研究では越流条件を 1 地点に限定しており，越水パターンの多様性に対する汎化性能の検証は不十分であった．

そこで本研究では，著者らが提案した 1 地点越流に対

応した浸水域予測手法を，実運用を想定して多地点越流条件に拡張し，さらに越流水深の時間的変化を反映させるために時系列データの特徴を考慮する手法を導入することで予測精度の向上を図った．具体的には，各越流条件に対して多様な越流水深パターンに基づく物理シミュレーションを実施し，12 時間後の浸水分布を作成した．これに対して SVD，NMF，AE の 3 手法で次元圧縮を行い，抽出した係数行列を目的変数，越流水深の時系列データを説明変数として DNN を用いて予測した．次に，次元圧縮手法のうち復元精度が最も低かった SVD を用いた DNN に着目し，係数行列の予測精度が浸水域予測に与える影響を検証した．この検証のため，時系列データの動的特徴を捉えることに優れる再帰型ニューラルネットワーク（RNN）を導入し，通常の RNN に加えて，長期依存関係を考慮可能な LSTM（Long Short-Term Memory）および GRU（Gated Recurrent Unit）を適用した．

2.　学習データについて

(1)　リアルタイム浸水域予測手法構築と解析の手順

本研究で開発したリアルタイム浸水域予測手法は，越流水深から浸水域を推定する深層学習手法に基づくものである．リアルタイム浸水域予測手法の全体的な処理フローは**図-1** に示す．**図-1** (a)は学習段階，**図-1** (b)は学習済みモデルを用いた推論段階を示している．学習段階では，さまざまな越流シナリオに基づき物理ベースの洪水シミュレーションを多数実施し，浸水域データを生成した．次に，各次元圧縮手法を適用し，特徴量と係数行列を抽出した．推論段階では，学習済みモデルに時系列の越流水深データを入力し，次元圧縮で抽出した係数行列を予測する．予測した係数行列と，あらかじめ抽出された特徴量を用いることで，最大 12 時間後の浸水域を面的に再構成する．この手法により，効率的な浸水域予測が可能となる．

(2)　浸水解析手法

浸水解析には，一言ら [11]が使用した氾濫水の挙動を高精度に表現可能な Dynamic Wave 法に基づく浸水解析手法を用いた．x，y方向の運動量保存式と質量保存式は以下のとおりである．

$$\frac{\partial M}{\partial t}+\frac{\partial}{\partial x}(uM)+\frac{\partial}{\partial y}(vN)+gh\frac{\partial H}{\partial x}$$

$$=-gh\frac{n^2u\sqrt{u^2+v^2}}{R^{\frac{4}{3}}} \qquad (1a)$$

$$\frac{\partial N}{\partial t}+\frac{\partial}{\partial x}(uN)+\frac{\partial}{\partial y}(vN)+gh\frac{\partial H}{\partial y}$$

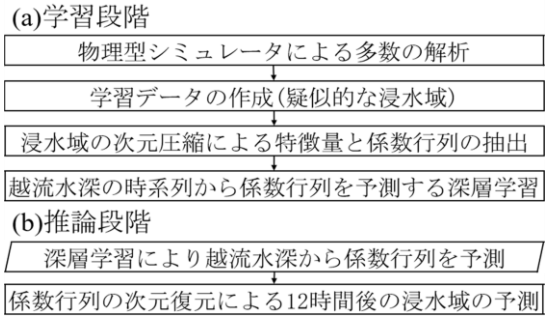

図-1　リアルタイム浸水域予測手法の処理フロー

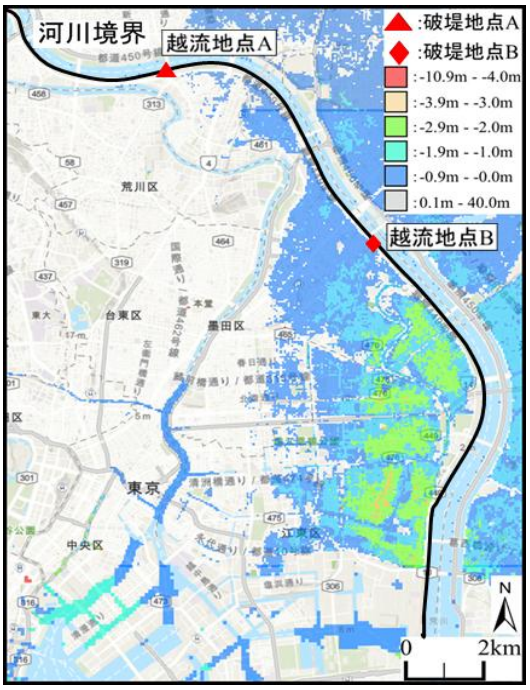

図-2　対象計算地域とその標高

$$=-gh\frac{n^2v\sqrt{u^2+v^2}}{R^{\frac{4}{3}}} \qquad (1b)$$

$$\frac{\partial h}{\partial t}+\frac{\partial M}{\partial x}+\frac{\partial N}{\partial y}=0 \qquad (1c)$$

ここで，$M=uh$はx方向の単位幅流量(m²/s)，$N=vh$はy方向の単位幅流量(m²/s)，uはx方向の平均流速(m/s)，vはy方向の平均流速(m/s)，hは水深(m)，Hは基準面からの水位(m)，Rは径深(m)，gは重力加速度(m/s²)，nはマニングの粗度係数(m$^{1/3}$・s)である．空間方向の離散化には有限差分法（中心差分）を，時間方向には陽解法（オイラー法）を使用し，タイムステップは 0.2 秒とした．また，粗度係数は基盤地図情報に基づく土地利用分類 [12]により設定した．

(3)　学習データ

本研究で使用する学習データの対象地域（解析領域）を**図-2** に示す．対象地域は東京都荒川区および台東区の一部であり，荒川右岸からの越流を想定した．対象地域

には標高 0m 以下の低地が広く分布している．なお，標高データや土地利用データには国土地理院の国土数値情報[12]を使用した．本研究の解析領域は**図-2** である．解析には25mの格子を用い，標高・土地利用は最近隣内挿法で設定した．解析領域全体の格子分割については 404×548 とした．越流水深の入力位置は，**図-2** に示す荒川右岸側に設定した．また，シミュレーションおよび深層学習に使用する越流水深の入力データには，以下の式で与えられる疑似的な越流水深データを用いた．

$$h = \left\{\sin\left(a - 0.5 + \pi \times \frac{t}{720}\right) + 0.3b\right\} \times 2c \qquad (2)$$

ここで，tは時間（分），a，b，cは，各ケース内で一定の 1 以下の正の乱数であり，一様分布から与えた．(2)式に従って越流水深hを計算し，0 以下の越流水深hが生成された場合は$h = 0$とした．越流水深データは，地点 A から越流した条件，地点 B から越流した条件，地点 A・B の両地点から越流した条件の 3 つを設定し，各条件 1,000case の計 3,000case を作成した．なお，地点 A・B の両地点から越流した場合を以後，同時越流と定義する．

代表例として，平均越流水深が最大となるケースを case A，最小となるケースを case B とし，それぞれの越流水深データを**図-3** に示す．次に，各越流水深を入力として実行した浸水解析手法により得られた 12 時間後の浸水域分布を，**図-4** に示す．**図-4** は，**図-3** に示した越流水深のうち，case A を各条件に適用して 12 時間後の浸水域をシミュレーションした結果である．**図-4** より，越流地点の違いによって浸水分布が大きく異なることが確認できる．以上のように，越流水深データを入力とする氾濫解析を各条件で 1,000 ケースずつ実行し，合計 3,000 ケースの学習データを作成した．

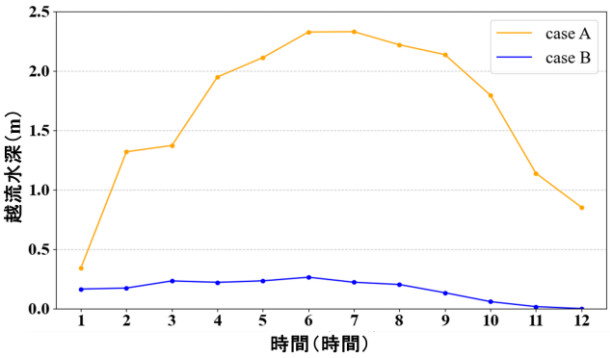

図-3　越流水深データについて

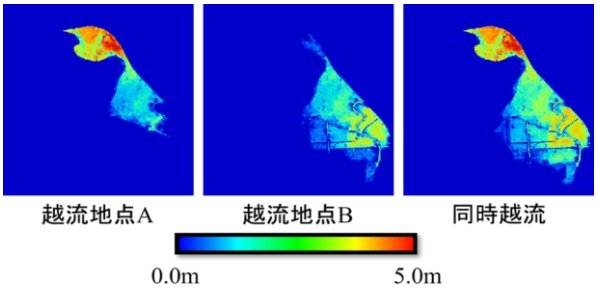

図-4　浸水解析手法で得た 12 時間後の浸水域(case A)

3.　次元圧縮手法及び予測手法

(1)　次元圧縮手法

次元圧縮は，高次元のデータの重要な特徴を保持したまま低次元で表現する方法である．データの本質的な特徴を保ちつつ，次元数を減らすことで深層学習が推論に要する計算効率が向上する．特に大規模データを扱う機械学習において有効である．以下では，本研究で使用した各次元圧縮手法を説明する．

a)　特異値分解

次元圧縮手法の 1 つである SVD は，行列を複数の特異ベクトルとそれに対応する特異値に分解する手法である．SVDは以下の式で示され，$n \times m$の行列Aは次のように分解される．

$$A = U \sum V^T \qquad (3a)$$

$$U = \begin{pmatrix} u_{1,1} & \cdots & u_{1,m} \\ \vdots & \ddots & \vdots \\ u_{m,1} & \cdots & u_{m,m} \end{pmatrix} = (\overrightarrow{u_1}\ \overrightarrow{u_2} \cdots \overrightarrow{u_n}) \qquad (3b)$$

$$\sum = \begin{pmatrix} a_{1,1} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & a_{n,n} \end{pmatrix} \qquad (3c)$$

$$V^T = \begin{pmatrix} v_{1,1} & \cdots & v_{1,n} \\ \vdots & \ddots & \vdots \\ v_{n,1} & \cdots & v_{n,n} \end{pmatrix} = (\overrightarrow{v_1}\ \overrightarrow{v_2} \cdots \overrightarrow{v_n}) \qquad (3d)$$

ここで，Uは$m \times m$の左特異ベクトル行列（係数行列），$\sum$は$n \times m$の対角行列で，対角成分には特異値が降順に並ぶ．ただし，nは通常Aのランクよりも小さい．V^Tは$n \times n$の右特異ベクトル行列の転置行列で特徴量を示す．この時，SVD における特異値は行列Aの特徴量の重要度を示す．特異値が大きいほど，特異値に対応する特異ベクトルが重要な特徴量を表す．一方で，特異値が 0 に近いほど対応する特異ベクトルは復元する際に重要でない情報を表している可能性が高い．本研究では，浸水域を SVD による分解で得られる係数行列Uを目的変数とする．

b)　非負値行列因子展開

次元圧縮手法の 1 つである NMF は，行列Aを基底行列Wと係数行列Hの 2 つに分解する多変量解析手法の一つである．NMF は以下の式で示され，行列Aを次のように分解される．

$$A \approx WH \qquad (4a)$$

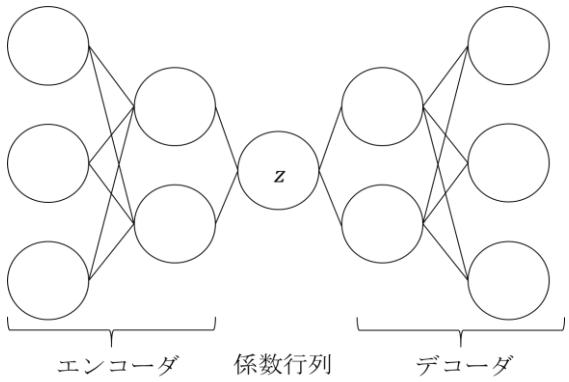

図-5　オートエンコーダの概略図

$$W = \begin{pmatrix} w_{1,1} & \cdots & w_{1,r} \\ \vdots & \ddots & \vdots \\ w_{m,1} & \cdots & w_{m,r} \end{pmatrix} \tag{4b}$$

$$H = \begin{pmatrix} h_{1,1} & \cdots & h_{1,n} \\ \vdots & \ddots & \vdots \\ h_{r,1} & \cdots & h_{r,n} \end{pmatrix} \tag{4c}$$

ここで，Wは$m \times r$の直交行列（基底ベクトル），Hは$r \times n$の行列（係数行列）である．行列Aの特徴量はWで示される．ただし，rは通常Aのランクよりも小さい．また，NMF の目的は，非負値行列AをWとHの 2 つの非負値行列の積で近似することである．よって，NMF は非負の制約があるため，分解・再構成の過程で負の値を生じることがなく，数値的に減算を伴わないという特徴を持つ．本研究では，浸水解析手法で得られた 12 時間後の浸水域を NMF によって分解して得られる係数行列Wを目的変数として用いる．

c)　オートエンコーダ

次元圧縮手法の一つである AE は，ニューラルネットワーク（Neural Network；NN）を用いて入力データを 1 度圧縮した後に再構成する手法である．AE の概略図を**図-5** に示す．AE はエンコーダとデコーダの 2 つのコンポーネントから構成される．各コンポーネントの式は以下に示すとおりである．

エンコーダ：入力データxを係数行列zに変換.

$$z = f(x) \tag{5a}$$

デコーダ：係数行列zからデータ$\hat{x}$を復元.

$$\hat{x} = g(z) \tag{5b}$$

本研究では，エンコーダで得られる係数行列 z を DNN の目的変数として用いる．AE の学習に適用した最適化アルゴリズムは Adam であり，損失関数は交差エントロピー誤差である．

(2)　深層学習手法

本研究では，深層学習手法としてディープニューラルネットワーク（DNN）を採用した．DNN の一例を**図-6** に示す．DNN は，多層の NN を用いて複雑なパターンや特徴を学習する代表的な機械学習手法の一つである．本研究における DNN では，説明変数に 1 時間後から 12 時間後までの越流水深（1 時間刻み），目的変数に各次元圧縮手法で得られた係数行列を用いた．DNN で予測した係数行列と，事前に抽出した特徴行列を掛け合わせることで，浸水域を再構成できる．

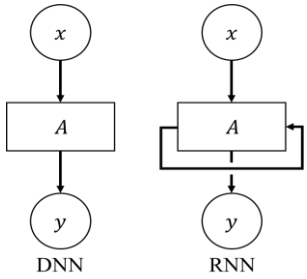

図-6　DNN・RNN の概略図

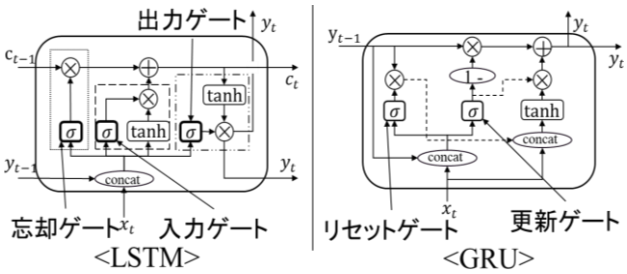

図-7　LSTM・GRU アーキテクチャについて

(3)　時系列学習手法

越流水深のような時系列データの動的特徴をより適切に捉えるため，本研究では RNN（Recurrent Neural Network），LSTM（Long Short-Term Memory），GRU（Gated Recurrent Unit）を採用した．これらの手法はいずれも時系列データから有用な特徴を抽出する能力に優れており，越流水深の時間変化と浸水域の空間的変化の関係性を学習する上で有効であると期待される．**図-6** に DNN 及び RNN の概略図，**図-7** に LSTM・GRU の概略図を示す．

a)　RNN

RNN は，過去の情報を内部状態として保持し，時系列データの時間的依存関係を学習可能なネットワークである．ただし構造は比較的単純である一方，長期的な依存関係の学習には限界があるとされる．

b)　LSTM・GRU

LSTM は RNN の改良版であり，入力ゲート・忘却ゲート・出力ゲートの 3 つのゲート機構を持つことで，長期的な依存関係の保持と学習に優れている．GRU は LSTM を簡略化した構造でリセットゲートと更新ゲートの 2 つを持ち，学習時間の短縮と高精度な予測が可能である．

(4)　標準化

本研究では，学習効率の向上および数値計算の安定性を確保するため，深層学習手法に入力する越流水深データには標準化処理を施した．標準化処理では，説明変数および目的変数をそれぞれ平均 0，分散 1 となるように変換した．具体的に以下の式を用いた．

$$x_{scaled} = \frac{x - \mu}{\sigma} \tag{6}$$

ここで，μ は平均，σ は標準偏差を表す．説明変数と目的変数にはそれぞれ個別のスケーラーを適用し，スケーリングは各変数の全データセットに基づいた．

(5)　実行条件・学習条件

本研究における次元圧縮の実行条件，および AE，DNN，RNN の学習条件を**表-1**，**2**，**3** に示す．次元圧縮を用いた浸水域の復元に関する評価指標には以下に示す 2 乗平均平方根誤差（Root Mean Square Error；RMSE）および差異を用いた．

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(a_i - f_i)^2} \tag{7}$$

$$差異 = a_i - f_i \tag{8}$$

なお，nは圧縮前の次元数，a_iは復元した浸水深，f_iはシミュレーションによる浸水深である．

(6)　開発環境

本研究の開発環境は以下の通りである．ハードウェアは，CPU：Intel Core i7-12700F，RAM：32GB，GPU：NVIDIA RTX 3070（8GB）を使用した．ソフトウェアは，Python 3.9 を用い，ライブラリとして TensorFlow-gpu=2.10.0，NumPy，scikit-learn を使用した．

4.　解析結果

多地点越流に対応した DNN を用いて各次元圧縮手法によって浸水域の復元結果について精度と計算時間で比較をした．また，RNN を用いた予測精度の改善についても検討を行い，本章ではこれらの解析結果を示す．

(1)　復元精度について

各次元圧縮手法における圧縮次元数と RMSE の関係を**図-8** に示す．**図-8** に示す RMSE は，各次元における全 3,000 ケースの平均値である．点線は，標準化を適用せずに DNN で予測した係数行列を用いて復元した場合，実線は標準化を適用した DNN で予測した係数行列を用いて復元した場合の RMSE を示している．**図-8** から，圧縮次元数が増加するにつれて RMSE が減少する傾向が確認できる．また，標準化を適用した場合は，標準化を適用しない場合と比べていずれの次元圧縮手法においても復元時の RMSE が小さくなった．この差より，標準化により数値計算の安定性が向上したと判断できる．特に SVD に標準化を適用した場合が最も効果的であった．RMSE の推移から，221,392 次元のデータを 10 次元に圧

表-1　次元圧縮の実行条件

対象データ	12 時間後の 3,000case の浸水域
入力次元数	221,392 次元(404×548)
次元圧縮手法	①　特異値分解 ②　非負値行列因子 ③　オートエンコーダ
圧縮次元数	1 から 20 次元の各次元
評価指標	RMSE・差異

表-2　オートエンコーダの学習条件

訓練データ	2,400case
テストデータ	600case
学習回数	50 回
中間層の数	2 層(256-128)
バッチサイズ	32
検証方法	交差分割

表-3　DNN・RNN の学習条件

訓練データ	2,400case
テストデータ	600case
説明変数	越流水深
目的変数	係数行列
学習回数	最大 500 回 （損失が 10 回連続で 低減しない場合早期終了）
中間層の数	DNN：4 層(128-64-32-16) RNN：1 層(64) LSTM：1 層(64) GRU：1 層(64)
バッチサイズ	32
損失関数	平均二乗誤差
検証方法	交差分割

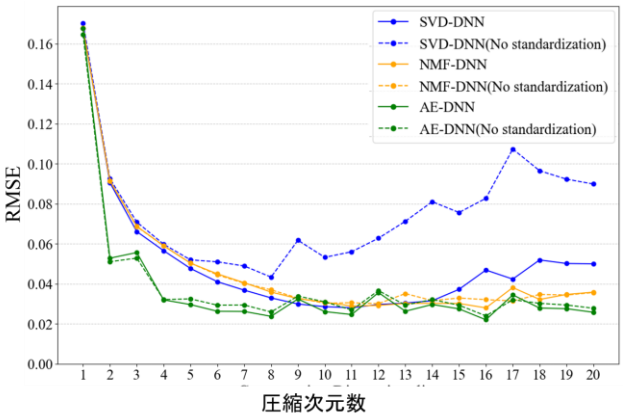

図-8　RMSE と圧縮次元数の関係（標準化の有無）

縮可能と考える．

(2) 越流水深最大及び最小ケースの可視化による評価

図-9 は，case A および case B における，地点 A からの越流，地点 B からの越流，および地点 A・B からの同時越流という各条件に対して，各次元圧縮手法を用いて 10 次元に圧縮した係数行列と，標準化を施した DNN を用いて復元した浸水域の予測結果を示す．なお，カッコ内の数値は case A，case B における RMSE を表す．図-10 は，case A，case B において予測値とシミュレーション値との差異を示したものである．図-9 と図-10 から，case A, case B のいずれのケース，どの越流条件および次元圧縮手法を適用した場合においても，可視化結果および RMSE 値から浸水域の予測が可能であることが確認された．従って，いずれの次元圧縮手法を用いた場合でも，元の浸水域データ（221,392 次元）の本質的な情報を保持しつつ，10 次元への圧縮後においても予測が可能である．

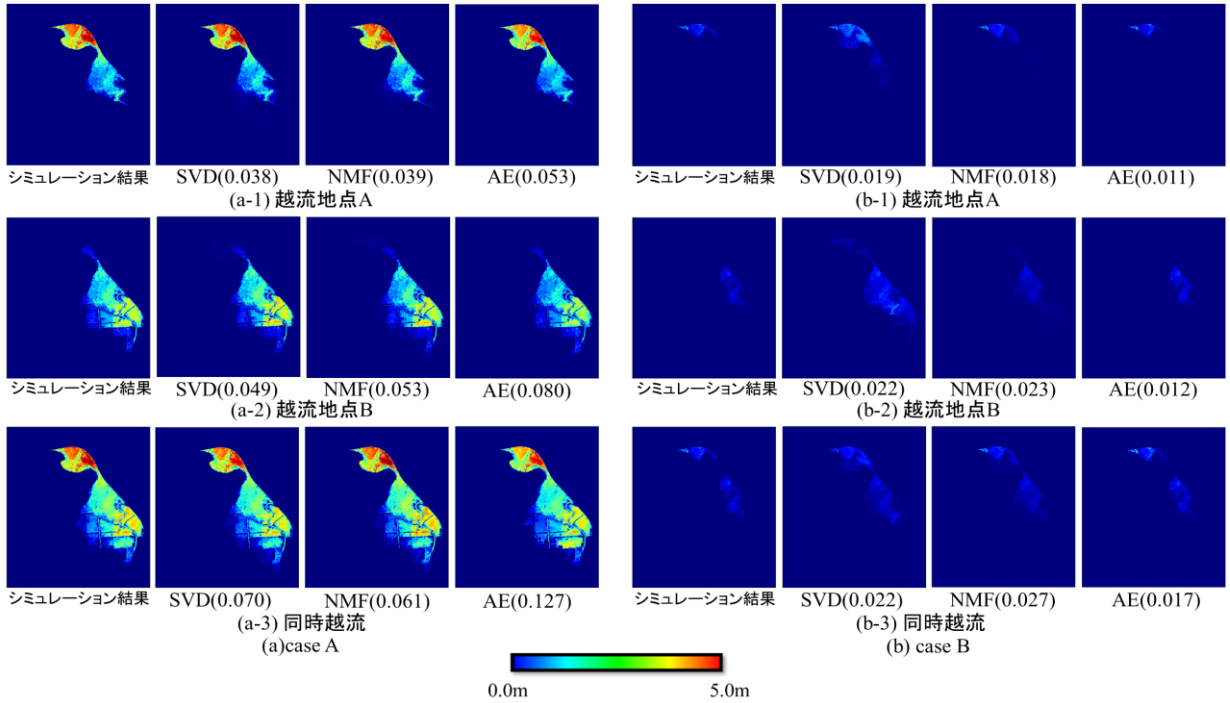

図-9　case A，case B の事例において，各次元圧縮手法を適用した浸水域の予測結果（10 次元）

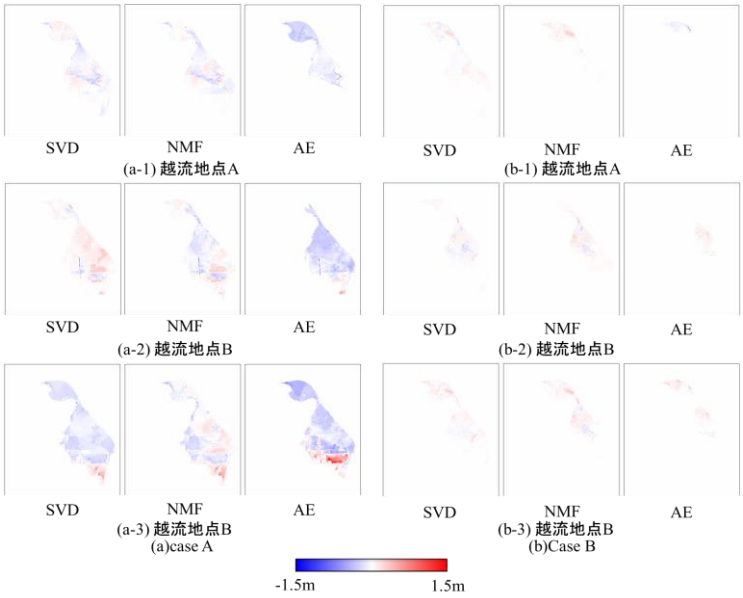

図-10　case A，case B の事例において，各次元圧縮手法を適用した予測値と解析値の差異（10 次元）

(3) 予測時間に関する検討

浸水域の予測に要した時間（深層学習による係数行列の推論時間と，次元圧縮手法による復元時間の合計）を**図-11** に示す．点線は標準化を適用せずに予測した結果，実線は標準化を適用した結果である．SVD および NMF を用いた場合の予測時間は最大約 3 秒，AE を用いた場合は最大約 4 秒であった．この差は，AE のパラメータ数が多く，計算負荷が高いためと考えられる．また，標準化の適用により，いずれの手法でも予測時間の短縮が確認された．物理ベースの浸水解析手法では，1 ケースの実行に約 212 秒を要した．一方，深層学習による係数行列の予測と浸水域の復元は，3,000 ケースで合計 2.5～4.0 秒と，大幅な高速化が実現された．次元数の増加による予測時間の増加が確認できなかったのは，元のデータが 221,392 次元と非常に高次元であり，20 次元程度の差が相対的に小さかったためと考えられる．以上より，深層学習による係数行列の予測と次元圧縮手法の併用により，従来の浸水解析手法と比較して計算時間を大幅に短縮できることが示された．

また，221,392 次元の浸水域データを 10 次元に圧縮しても予測が可能であり，情報が保持されていると考える．**図-8**，9，10，11 の結果より復元精度の観点では AE，復元時間の観点からは NMF を用いたリアルタイム浸水域予測手法が最も優れていると判断される．一方，SVD を用いた DNN では，圧縮次元数が 10 を超えると RMSE がやや上昇する傾向がみられた．この傾向は，DNN による予測精度が影響している可能性がある．次節では，DNN 以外の深層学習手法を適用した場合の予測精度を検証する．

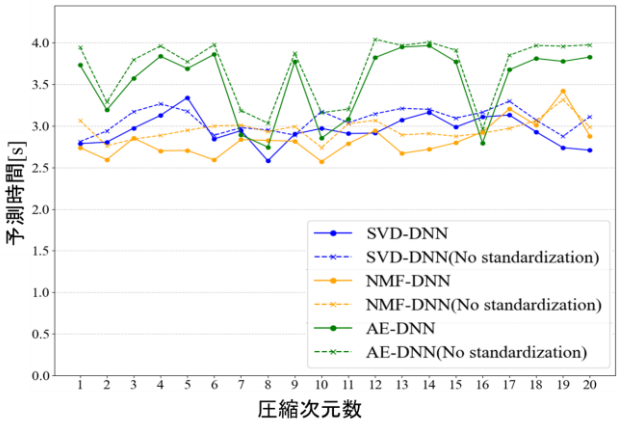

図-11　浸水域の予測に要する時間

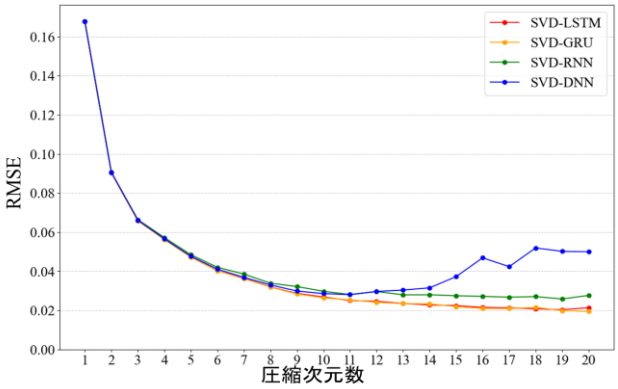

図-12　RMSE と圧縮次元数の関係(DNN と RNN の違い)

(4) 係数行列が及ぼす浸水域予測への精度の影響

係数行列の精度が与える影響を評価するため，SVD を用いて抽出した係数行列に対して，DNN のほか，RNN，GRU，LSTM の各深層学習手法を適用した．各深

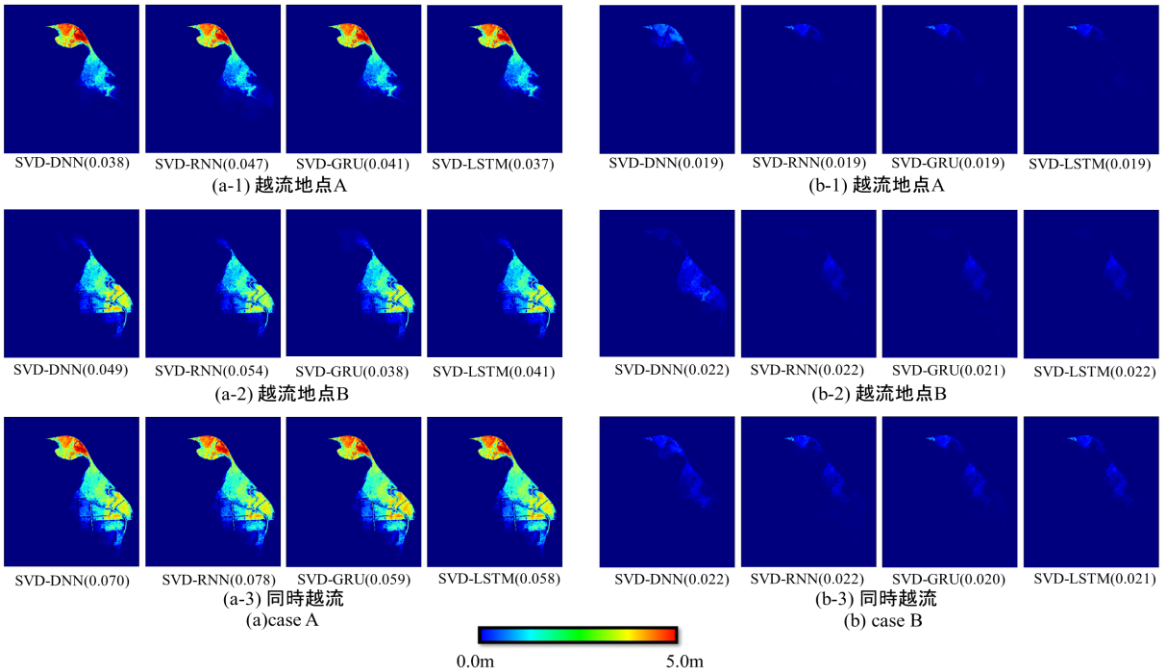

図-13　case A，case B の事例において，各深層学習手法を適用した浸水域の予測結果（10 次元）

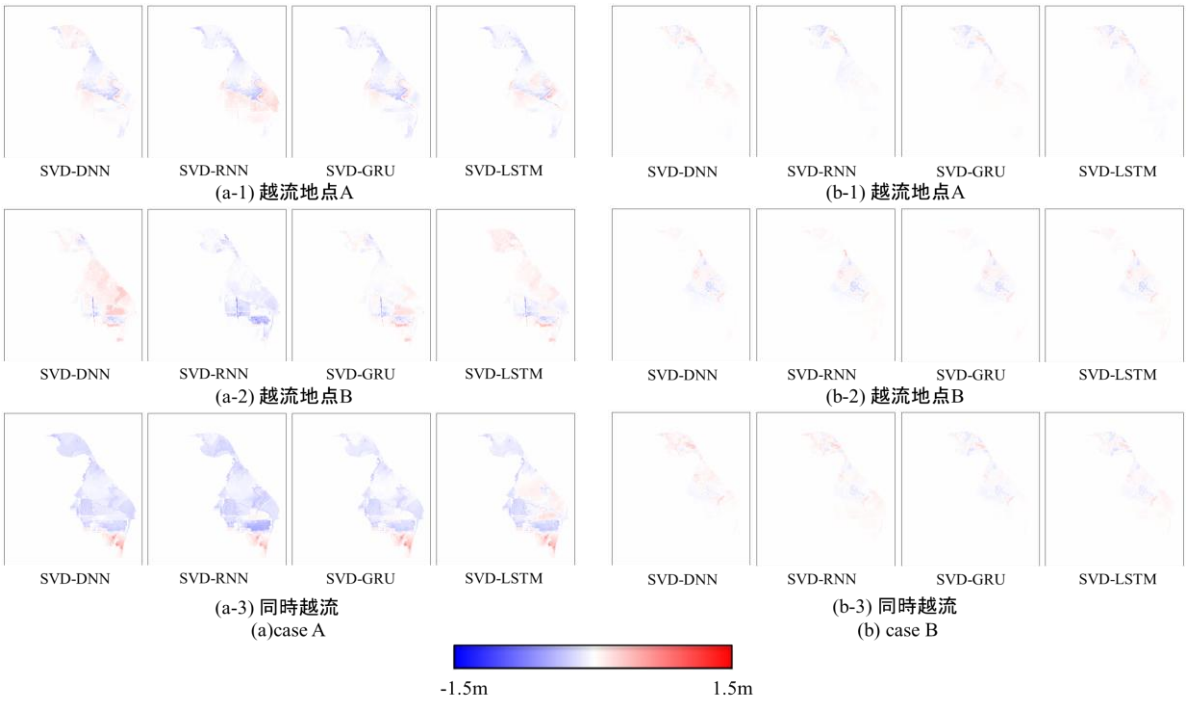

図-14　case A，case B の事例において，各深層学習手法を適用した予測値と解析値の差異（10 次元）

層学習手法を SVD に適用させた際の圧縮次元数と RMSE の関係を**図-12** に示す．**図-12** に示す RMSE は，各次元における全 3,000 ケースの平均値である．**図-13** は，case A, case B における，越流地点 A，B，同時越流の各条件に対し，SVD を用いて 10 次元に圧縮した係数行列と標準化を施した深層学習手法を用いて復元した浸水域の結果を示す．なお，カッコ内の数値は case A，case B における RMSE を示す．**図-14** は，case A，case B において予測値とシミュレーション値の差異の可視化を示す．**図-15** に圧縮次元数と予測時間の関係を示す．**図-12** から，RNN・ LSTM・GRU を用いた場合，DNN と比較して RMSE がより低く推移しており，予測精度が向上していることがわかる．**図-13**，**図-14** からは，case A，case B において LSTM・GRU がほとんどの越流条件下で DNN よりも差異が小さく精度が高く浸水域の予測が可能であることがわかる．また，RNN，LSTM，GRU のユニット数については検討の余地がある．一方で，**図-15** に示す通り，推論時間においては DNN が最も高速であることも確認した．この理由としては，RNN，LSTM，GRU が時間的依存関係を学習可能なネットワークである一方で，DNN と比較して計算コストが高いと考える．

6.　結論

本論文では，深層学習を用いた浸水域予測に次元圧縮技術を適用した手法の汎化性評価と予測精度向上を検討した．数値シミュレーションで得られた 3 つの異なる越

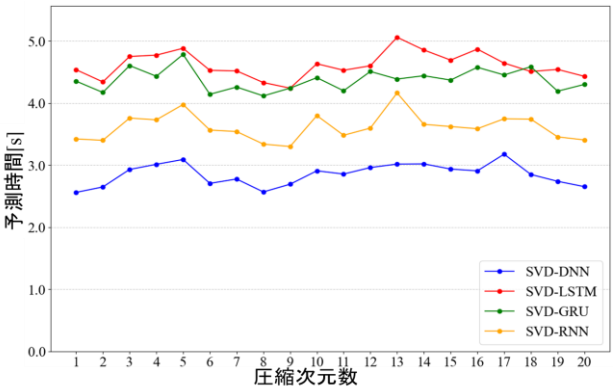

図-15　浸水域の予測に要する時間（DNN・RNN）

流条件に対して次元圧縮手法を適用し，抽出された係数行列を DNN，RNN，LSTM，GRU で予測し，抽出した特徴量と組み合わせて浸水域予測のケーススタディを実施した．これらの結果から，以下の結論を得た．

- 2 地点からの越流においても，DNN に次元圧縮手法を適用することで浸水域の予測時間の大幅な短縮と高精度の両立が可能であることを確認した．
- 本研究で採用した次元圧縮手法の中では，圧縮次元数と再現精度の観点から AE，圧縮次元数と復元時間の観点から NMF が最適と考える．また，圧縮次元数は 10 次元程度で高い復元精度であった．
- DNN と比較して LSTM は最も低い RMSE を示したが，その一方で推論時間は DNN と比較して増加し，精度と計算時間のトレードオフがある．

今後は，越流地点をさらに増やした場合の予測精度およ

び計算時間について検討を行うとともに，氾濫歴のある他河川での適用による妥当性の検証を行う予定である．また，社会実装に向けては，降雨データを用いた河川水位予測モデルとの連携について検討する予定である．

参考文献

1) Teng, J., Vaze, J. and Dutta, D.: Enhancing the Capability of a Simple, Computationally Efficient, Conceptual Flood Inundation Model in Hydrologically Complex Terrain. *Water Resources Management*, 2019.
2) Hoch, J. M., van Beek, R., Winsemius, H. C. and Bierkens, M. F. P.: Benchmarking flexible meshes and regular grids for large-scale fluvial inundation modelling. *Advances in Water Resources*, 2018.
3) Chang, L. C., Liou, J. Y. and Chang, F. J.: Spatial-temporal flood inundation nowcasts by fusing machine learning methods and principal component analysis. *Journal of Hydrology*, 2022.
4) Zhou, Y., Wu, W., Nathan, R. and Wang, Q. J.: A rapid flood inundation modelling framework using deep learning with spatial reduction and reconstruction. *Environmental Modelling and Software*, 2021.
5) Zhou, Y., Wu, W., Nathan, R. and Wang, Q. J.: Deep learning-based rapid flood inundation modeling for flat floodplains with complex flow paths. *Water Resources Research*, 2022.
6) Kao, I.-F., Liou, J.-Y. and Chang, F.-J.: Fusing stacked autoencoder and long short-term memory for regional multistep-ahead flood inundation forecasts. *Journal of Hydrology*, 2021.
7) 中山龍也，羽物裕人，一言正之，樫山和男：深層学習を用いたリアルタイム浸水域予測における次元圧縮の適用，AI・データサイエンス論文集 5 巻 3 号，p.563-571，2024
8) Eckart, C. and Young, G.: The approximation of one matrix by another of lower rank. *Psychometrika*, 1(3), 211–218, 1936.
9) Lee, D. D. and Seung, H. S.: Learning the parts of objects by non-negative matrix factorization. *Nature*, 401(6755), 788–791, 1999.
10) Rumelhart, D. E., Hinton, G. E. and Williams, R. J.: Learning representations by back-propagating errors. *Nature*, 323(6088), 533–536, 1986.
11) 一言正之，荒木光一，古木宏和：敵対的生成ネットワークによる洪水氾濫浸水域の推定，人工知能学会全国大会第 33 回，2019.
12) 国土地理院，国土基盤情報 https://www.gsi.go.jp/kiban/ (参照 2023-10-10)

(Received June 30, 2025)
(Accepted August 31, 2025)

Enhancement of real-time flood inundation prediction based on deep learning with dimensionality compression

Ryuya NAKAYAMA, Kanta YAMAGUCHI, Masayuki HITOKOTO and Kazuo KASHIYAMA

This paper presents a flood inundation prediction model that integrates deep learning with dimensionality compression as an alternative to conventional numerical simulation approaches. Three dimensionality compression techniques—Singular Value Decomposition (SVD), Non-negative Matrix Factorization (NMF), and Autoencoders (AE)—were evaluated in conjunction with various deep learning models, including Deep Neural Networks (DNN), Recurrent Neural Networks (RNN), Long Short-Term Memory (LSTM), and Gated Recurrent Units (GRU). The DNN-based model was applied to flood simulations of the Arakawa River to assess its feasibility and effectiveness in terms of both prediction accuracy and real-time performance. Given the temporal nature of inundation dynamics, time-series models such as RNN, LSTM, and GRU were employed to capture temporal dependencies. Results showed that high-accuracy and high-speed prediction is achievable even when the original 221,392-dimensional inundation data is compressed to a 10-dimensional representation. Among the tested methods, NMF exhibited the best balance between accuracy and computational efficiency. Furthermore, LSTM demonstrated superior prediction accuracy compared to DNN.